

系统设计

Distributed System Design (九章网站下载最新课件)

课程版本 v5.1 本节主讲人: 老顽童

版权声明:九章课程不允许录像,否则将追究法律责任,赔偿损失



扫描二维码关注微信/微博 获取最新面试题及权威解答

微信: ninechapter

微博: http://www.weibo.com/ninechapter

知乎: http://zhuanlan.zhihu.com/jiuzhang

官网: http://www.jiuzhang.com

Copyright © www.jiuzhang.com 第1页



什么是分布式系统?

一言以概之:用多台机器去解决一台机器上不能够解决的问题。

比如:存储不够? QPS太大?







Copyright © www.jiuzhang.com 第2页

Overview 谷歌三剑客



- Distributed File System (Google File System)
 - 怎么有效存储数据?
 - No SQL 底层需要一个文件系统
- Map Reduce
 - 怎么快速处理数据?
- Bigtable = No-SQL Database
 - 怎么连接底层存储和上层数据

第3页

Overview of today



• Design Distributed File System (Google File System)

Copyright © www.jiuzhang.com 第4页

你会掌握



• Master Slave Pattern.

• How to check and handle system failure and error.

• How to design Distributed File System.

Copyright © www.jiuzhang.com



Design Distributed File System 了解分布式文件系统后可以做什么?

- 1. Google, Microsoft面试可能会考到.
- 2. 学习经典系统,对其他系统设计也有帮助. 比如如何处理failure 和 recovery.

第6页



| Distributed File System | Company | 开源 |
|-------------------------|------------------------------------|-----|
| GFS | Google | No |
| HDFS | Yahoo(Altaba)Open Source of GFS | Yes |

Distributed File System

Hadoop Distributed File System VS

Google File System(GFS)

Overview



- 1. 按照4S分析
 - **S**cenario 场景分析
 - Service 服务
 - Storage 存储
- 2. 理清楚work solution
- 3. Scale 升级优化



Scenario 场景分析

需要设计哪些功能

Copyright © www.jiuzhang.com 第9页

Scenario 场景分析



- 需求1
 - 用户写入一个文件, 用户读取一个文件.
 - 支持多大的文件?
 - 越大越好? 比如 >1000T
- 需求2
 - 多台机器存储这些文件
 - 支持多少台机器?
 - 越多越好? 10万台/ Data Center, Google



Service 服务

Copyright © www.jiuzhang.com 第11页



Service 服务

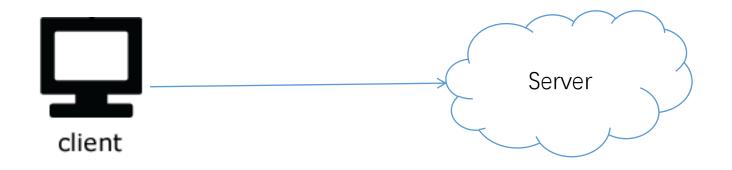
Client

+

Server

Copyright © www.jiuzhang.com 第12页





Copyright © www.jiuzhang.com 第13页

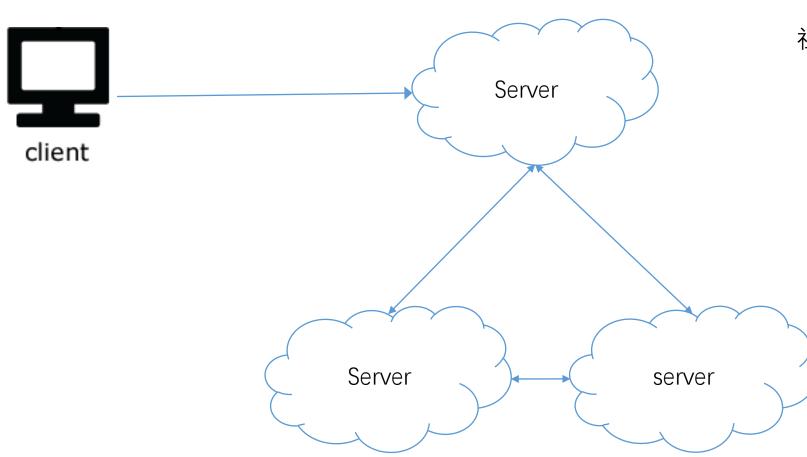


多台机器怎么沟通?

社会主义 + 资本主义

Copyright © www.jiuzhang.com 第14页



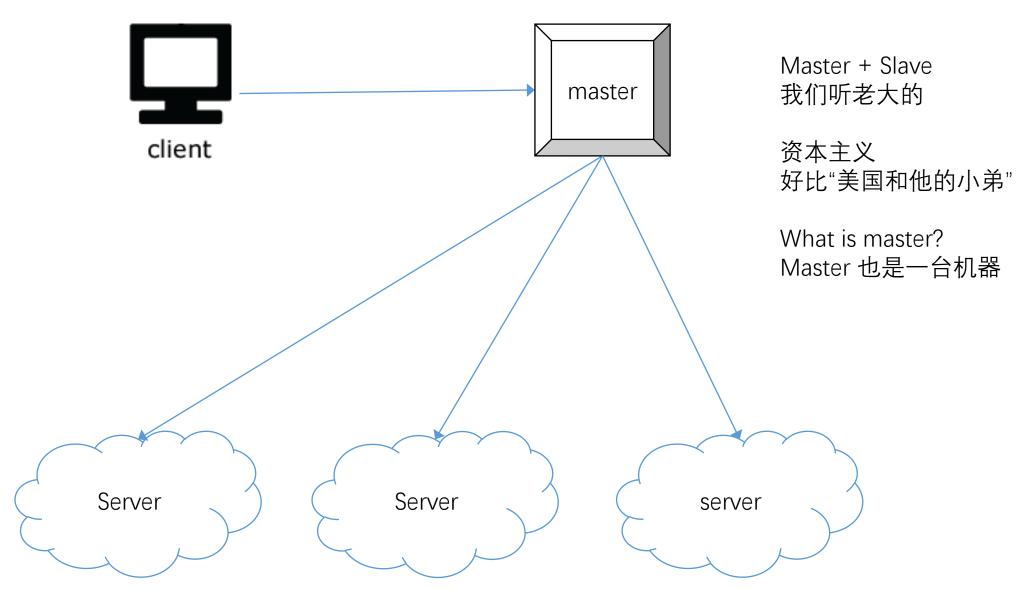


Peer to peer 谁也看不惯谁

社会主义

Copyright © www.jiuzhang.com





Copyright © www.jiuzhang.com



| | DB | GFS (HDFS) |
|--------|--------|--------------------------|
| Master | 存储数据 | 管理者 (不存储数据) |
| Slave | Backup | 被管理者(存储实际文件,partition关系) |

Copyright © www.jiuzhang.com 第17页



- Peer 2 Peer (BitComet, Cassandra, 不是课程重点,考察比较少)
 - Advantage
 - 一台机器挂了还可以工作
 - Disadvantage
 - 多台机器需要经常通信保持他们数据一致
- Master Slave
 - Advantage
 - Simple Design
 - 数据很容易保持一致
 - Disadvantage
 - 单master要挂
- Final Decision
 - Master + Slave
 - 单master挂了重启就是。



数据如何存储

Copyright © www.jiuzhang.com 第19页



- 大文件存在哪?
 - 内存?数据库?文件系统?

Copyright © www.jiuzhang.com 第20页



- 大文件存在哪?
 - 内存?数据库?文件系统?
- 怎么存在文件系统里面呢?
 - 操作系统基础知识怎么存文件的?

Copyright © www.jiuzhang.com 第21页



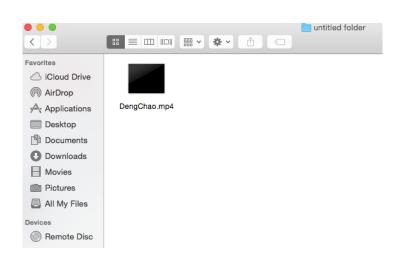
Interviewer: How to save a file in one machine?

普通的操作系统是怎么做的呢? 100G

Copyright © www.jiuzhang.com 第22页



DengChao.mp4 一个文件有什么东西?





Copyright © www.jiuzhang.com 第23页



Disk

Metadata

File info

Name=dengchao.mp4 CreatedTime=201505031232 Size=2044323 dengchao.mp4

Metadata: 描述"其他数据"而存储的信息

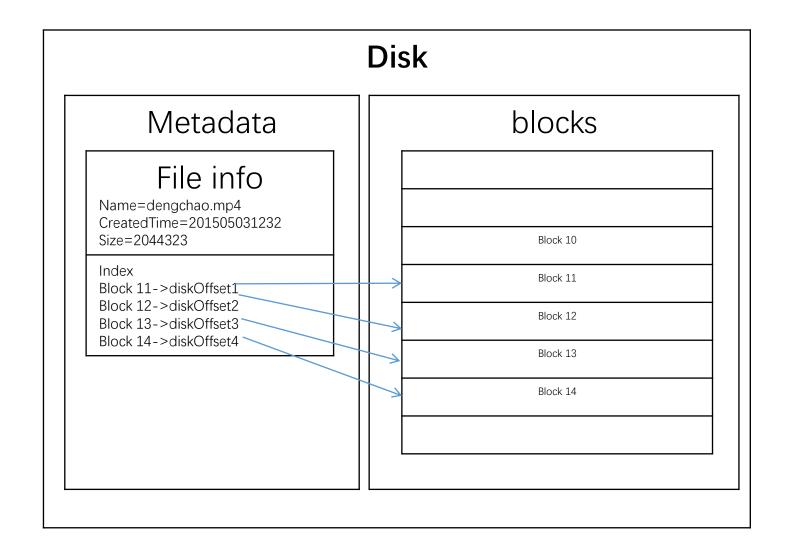
Metadata 访问 常常多于 内容的访问

Metadata 和文件内容是存在一起还是分开?

文件内容是分开存储的呢?还是连续存储的呢?







Key point

• 1 block = 4096Byte

Copyright © www.jiuzhang.com 第25页



Interviewer: How to save a large file in one machine?

Is block size big enough?

100T(多文件)

=100*1024G

=100*1024*1024M

=100*1024*1024*1024K

=25*1024*1024*1024block

Copyright © www.jiuzhang.com 第26页

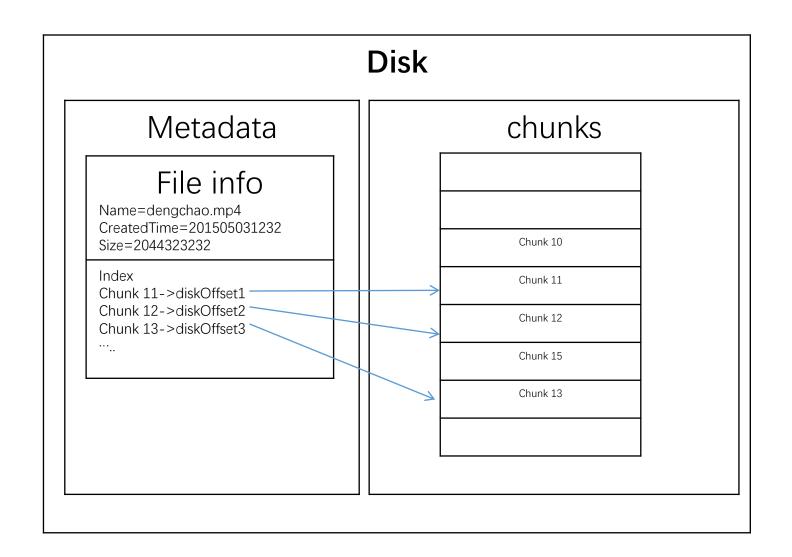


通常大文件是一些数据文件合成的 file-merged.txt = 0.3G

Copyright © www.jiuzhang.com 第27页

Interviewer: How to save a large file in one machine?





Key point

• 1 Chunk= 64M = 64*1024K

Advantage

Reduce size of metadata

Disadvantage

• Waste space for small files

Copyright © www.jiuzhang.com 第28页



系统设计没有标准答案 就是Tradeoff的过程



Interviewer: How to save extra-large file in several machine?

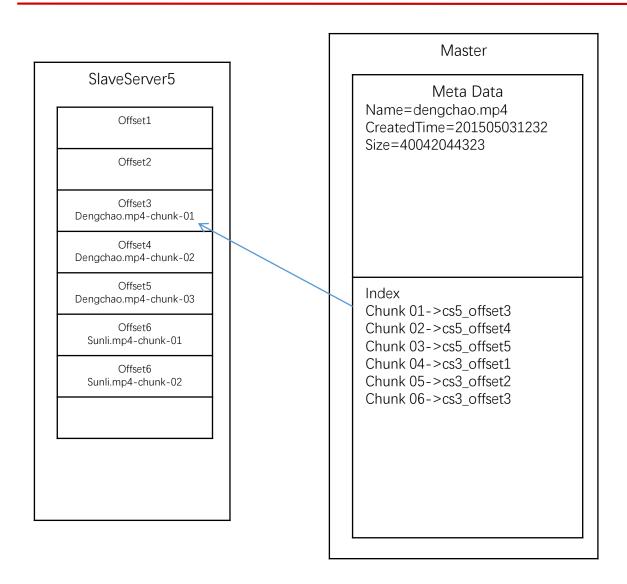
10P

Is one machine big enough?

这里的文件并不是指一个dengchao.mp4就那么大而是很多个文件

Scale about the Storage





Key point

• One master + many Chunk Servers

Slave Servers = Chunk Servers

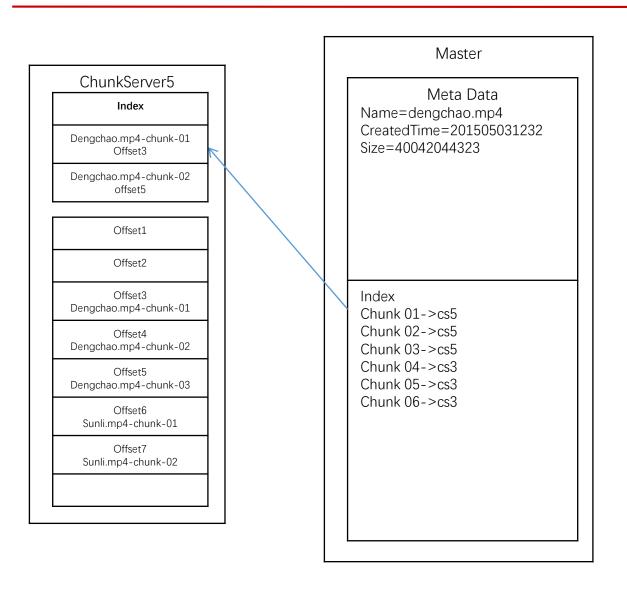


每个chunk的Offset偏移量可不可以不存在master上面?

Copyright © www.jiuzhang.com 第32页

Scale about the Storage





Key point

• The master don't record the disk Offset of a chunk

Advantage

- Reduce the size of metadata in master
- Reduce the traffic between master and Chunk Server (chunk offset改变 不需要通知master)

Copyright © www.jiuzhang.com 第33页



Master 存储10P 文件的metadata 需要多少容量?

1 chunk = 64MB needs 64B. (经验值) 10P needs 10G

Copyright © www.jiuzhang.com 第34页

Overview



- 按照4S分析
 - **S**cenario 场景分析
 - Service 服务
 - Storage 存储
- 理清楚work solution
- Scale 升级优化

Copyright © www.jiuzhang.com



One Work Solution for Read / Write



Copyright © www.jiuzhang.com 第36页



Interviewer: How to write a file?

Copyright © www.jiuzhang.com 第37页

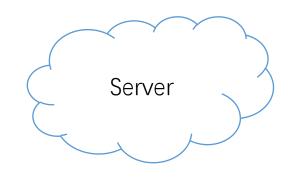


一次写入 还是拆分成多份多次写入?



write File_name=/gfs/home/dengchao.mp4

把大胖子直接写入呢? 还是把大胖子碎尸万段了后写入呢?



一次 VS 多次



- 写入过程中出错了, 那么需要重新写入, 哪一种方法更好?
 - 一次传输得重新传输整个文件, 多次只用重新传一小份。
- 如果是分成多份多次写入,那么每一份的大小?
 - 文件本来是按照Chunk来存储的,所以传输单位也是Chunk

Copyright © www.jiuzhang.com 第39页



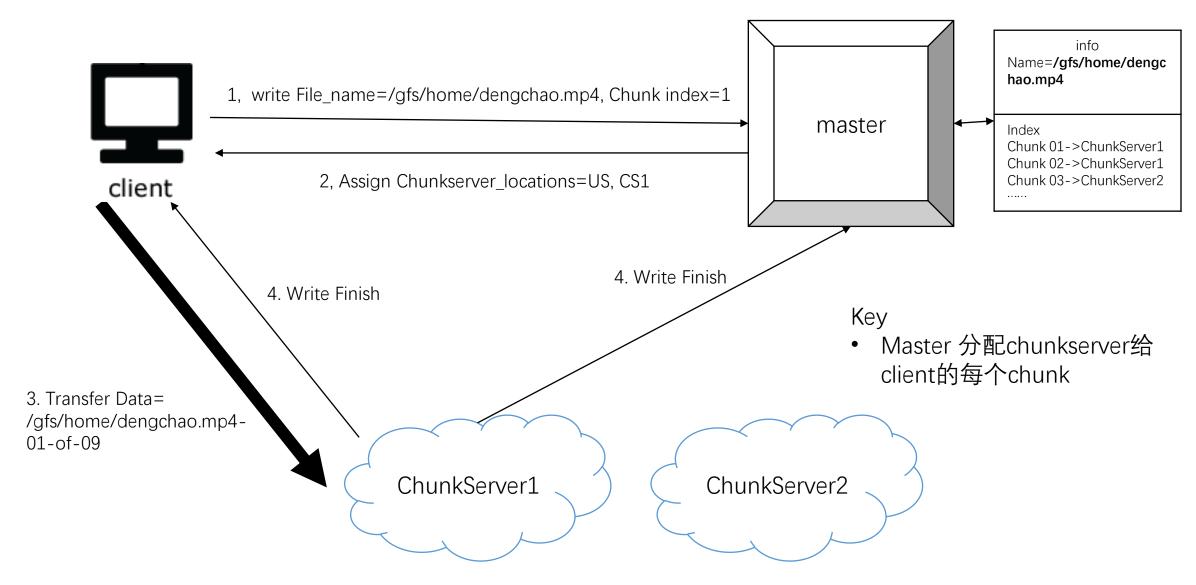
那每一个chunk是怎么写入server的呢?

直接写到chunk server?

需要先个master沟通,再写入chunk server?

How to write a file?





Copyright © www.jiuzhang.com 第41页



要修改Dengchao.mp4怎么办?

/gfs/home/dengchao.mp4

要修改的部分在哪个chunk?

修改了过后chunk变大了要怎么处理?

修改了过后chunk变小了要怎么处理?

Copyright © www.jiuzhang.com 第42页



要修改Dengchao.mp4怎么办?

One time to write, Many time to read. 先删掉/gfs/home/dengchao.mp4 重新把整个文件重写一份

第43页

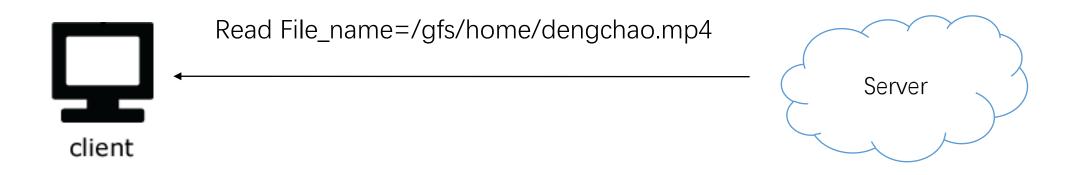


Interviewer: How to read a file?

Copyright © www.jiuzhang.com 第44页



一次读整个文件? 还是拆分成多份多次读入?



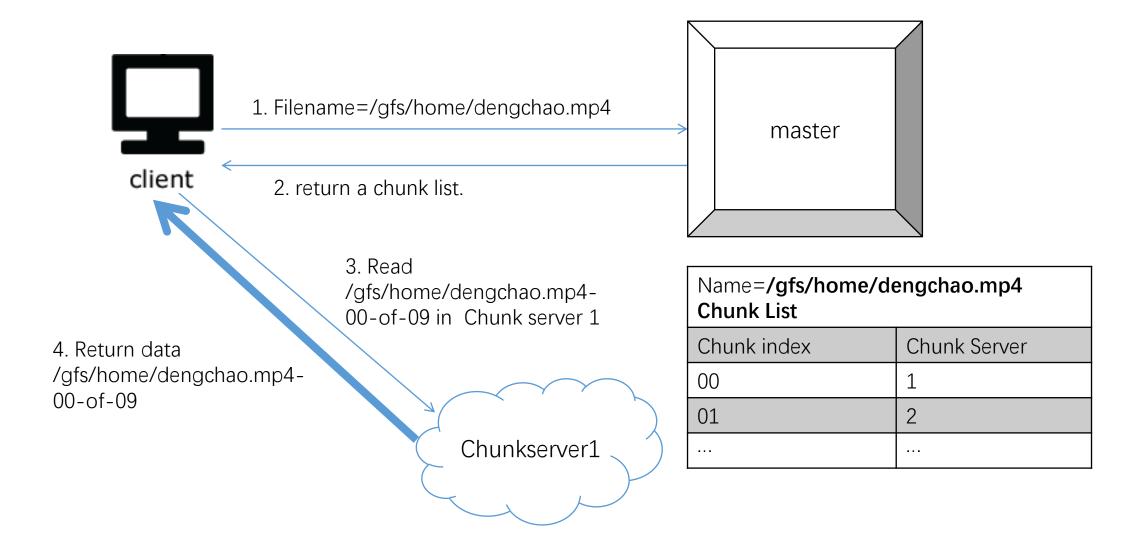
Copyright © www.jiuzhang.com 第45页



那么client怎么知道dengchao.mp4被切成了多少块?

How to read from a file?





Copyright © www.jiuzhang.com 第47页

Master Task



• 存储各个文件数据的metadata

- 存储Map(file name + chunk index -> chunk server)
 - 读取时找到对应的Chunk Server
 - 写入时分配空闲的Chunk Server

Copyright © www.jiuzhang.com 第48页

One Work Solution



• 存储

- 普通文件系统 Meta Data, Block
- 大文件存储: Block-> Chunk
- 多台机器超大文件: Chunk Server + Master

写入

- Master + Client + Chunk Server 沟通流程
- Master 维护metadata 和 Chunk Server 表

• 读出

• Master + Client+ Chunk Server 沟通流程



Scale 升级

系统如何优化与维护 GFS的精髓

第50页



单Master 够不够?

Copyright © www.jiuzhang.com 第51页



单Master 够不够?

工业界90%的系统都采用单master Simple is perfect

Copyright © www.jiuzhang.com 第52页



Single Master Failure

Double Master

Paper: Apache Hadoop Goes Realtime at Facebook

Multi Master

Paper: Paxos Algorithm



Scale about the Failure and Recover



Copyright © www.jiuzhang.com 第54页



Interviewer: How to identify whether a chunk on the disk is broken?

Copyright © www.jiuzhang.com 第55页



Checksum

Copyright © www.jiuzhang.com 第56页

Check Sum 检查一位错误



原来

| 数据 | 1 | 2 | 3 | Checksum(xor) |
|-------|----|----|----|---------------|
| 二进制表示 | 01 | 10 | 11 | 00 |

错误后

| 数据 | 1 | 3 | 3 | Checksum(xor) |
|-------|----|----|----|---------------|
| 二进制表示 | 01 | 11 | 11 | 01 |

- Checksum Method (MD5, SHA1, SHA256 and SHA512)
- Read More: https://en.wikipedia.org/wiki/Checksum

How to identify whether a chunk on the disk is broken?



- 1 Checksum size?
- 4bytes = 32bit
- 1 chunk = 64MB
- Each chunk has a Checksum
- The size of Checksum of 1P file
- 1P/64MB*32bit = 62.5 MB



什么时候写入checksum?

Copyright © www.jiuzhang.com 第59页



什么时候写入checksum?

Answer: 写入一块chunk的时候顺便写入

Chunk

Copyright © www.jiuzhang.com 第60页



什么时候检查checksum?

Copyright © www.jiuzhang.com 第61页



什么时候检查checksum?

Answer: 读入这一块数据的时候检查

- 1. 重新读数据并且计算现在的checksum
- 2. 比较现在的checksum和之前存的checksum是否一样

第62页



Interviewer: How to avoid chunk data loss when a Chunk Server is down/fail?

Copyright © www.jiuzhang.com 第63页



Interviewer: How to avoid data loss when a Chunk Server is down/fail?

Answer: Replica (专业词汇)

做备份

Copyright © www.jiuzhang.com 第64页



需要多少个备份?每个备份放在哪?

第65页



需要多少个备份?每个备份放在哪?

- 1. 三个备份都放在一个地方(加州)。
- 2. 三个备份放在三个相隔较远的地方(加州, 滨州, 纽约州)
- 3. 两个备份相对比较近,另一个放在较远的地方(2个加州,1个 滨州)



Interviewer: How to recover when a chunk is broken?

Copyright © www.jiuzhang.com 第67页

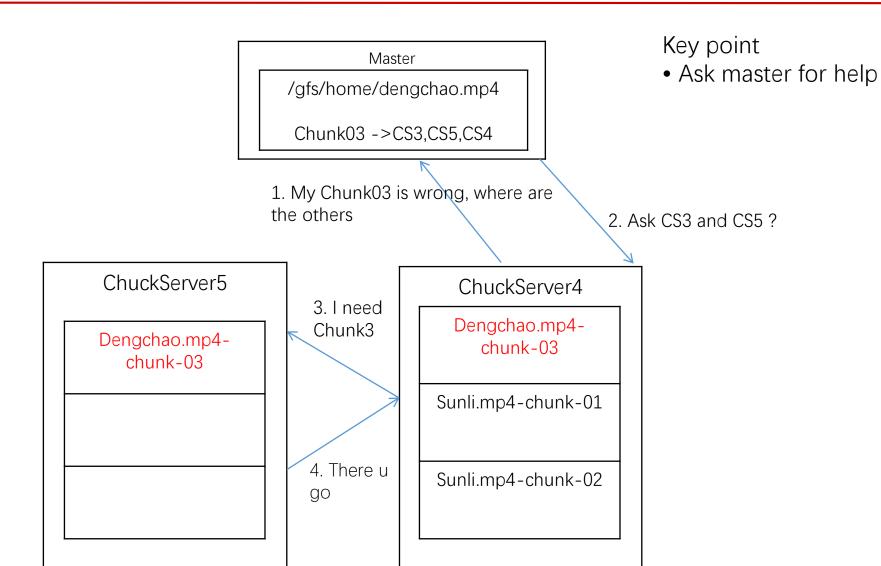


Interviewer: How to recover when a chunk is broken?

Answer: Ask master for help

第68页





Copyright © www.jiuzhang.com 第69页



How to find whether a Chunk Server is down?

Copyright © www.jiuzhang.com 第70页



How to find whether a Chunk Server is down?

Answer: Heart Beat.

A: master -> chunk servers?

B: chunk servers->master?

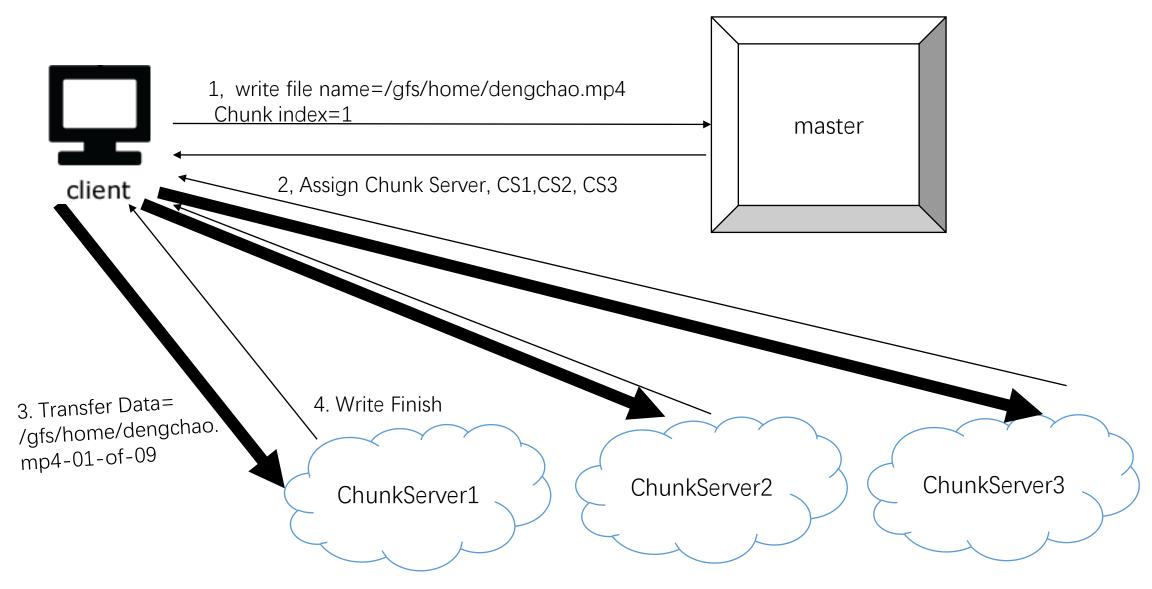


Scale about the Write

Interviewer: Whether write to only one server is safe?

Copyright © www.jiuzhang.com 第72页





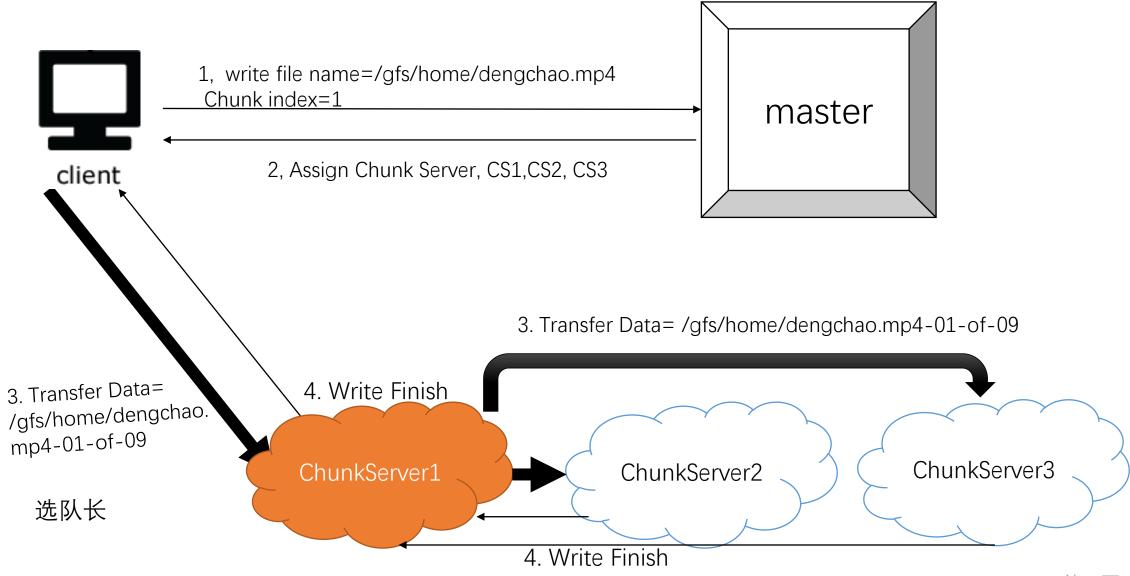
Copyright © www.jiuzhang.com



Interviewer: How to solve Client bottleneck?

Copyright © www.jiuzhang.com 第74页





Copyright © www.jiuzhang.com



Interviewer: 怎么样选队长?

- 1. 找距离最近的(快)
- 2. 找现在不干活的(平衡traffic)

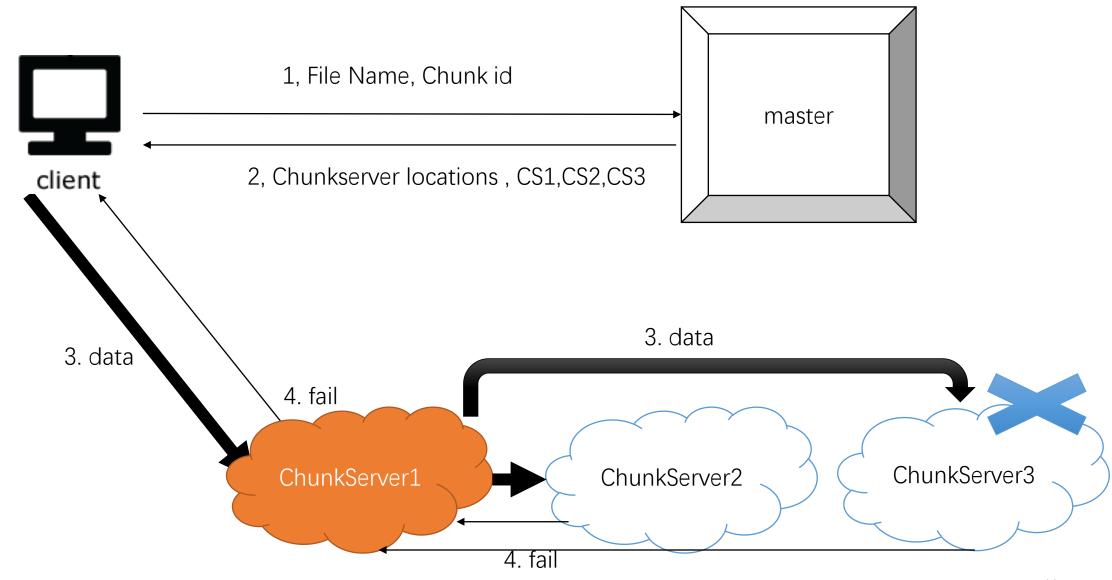
Copyright © www.jiuzhang.com 第76页



Interviewer: How to solve Chunk Server failure?

Copyright © www.jiuzhang.com 第77页





Copyright © www.jiuzhang.com







Copyright © www.jiuzhang.com

总结 Summary



- Key Point: Master-Slave
- Storage:
 - Save a file in one machine -> a big file in one machine -> a extra big file in multi-machine
 - Multi-machine
 - How to use the master?
 - How to traffic and storage of master?
- Read:
 - The process of reading a file
- Write:
 - The process of writing a file
 - How to reduce master traffic?
 - Client 和 Chunk Server沟通
 - How to reduce client traffic?
 - Leader Election
- Failure and Recover (key)
 - Discover the failure a chunk?
 - Check Sum
 - Avoid the failure a chunk?
 - Replica
 - Recover the failure?
 - Ask master
 - Discover the failure of the Chunk Server?
 - Heart Beat
 - Solve the failure of writing Chunk Server?
 - Retry



Google onsite non-abstract large scale system design 真题

https://www.jiuzhang.com/qa/627/

Read More



- Expert/Master, http://url.cn/dOLFCs
- Expert/Master, http://url.cn/eErkhm
- Expert/Master, http://url.cn/LqTkoa

- 为什么说学习GFS对我们其他的系统设计也有好处呢?
 - Master Slave Pattern
 - How to handle failure
 - How to use GFS





扫描二维码关注微信/微博 获取最新面试题及权威解答

微信: ninechapter

知乎专栏: http://zhuanlan.zhihu.com/jiuzhang

微博: http://www.weibo.com/ninechapter

官网: www.jiuzhang.com